


Seguimiento de distribuciones implícitas y gestión diaria de posiciones

Guía técnica del proceso: de las cotizaciones de opciones a la decisión sobre la posición



tres capas separadas, cada una con su propia evidencia

Alcance. Este documento explica, etapa por etapa, la arquitectura y el programa de experimentos de un sistema independiente que mide lo que descuentan las opciones, evalúa si esa información mejora los pronósticos de rendimiento y riesgo, y compara mantener o modificar una posición. **No presenta resultados empíricos ni modelos entrenados.** Todas las figuras numéricas se construyen con datos *sintéticos* y semillas fijas (apéndice D); sirven para explicar el método, no para sugerir su desempeño.

Contenido

Resumen ejecutivo	1
1 Producto y pregunta de investigación	3
1.1 Qué hace el sistema en cada sesión	3
1.2 Hipótesis principal y cómo se contrasta	3
1.3 Alcance de la primera versión	4
1.4 Tres horizontes que no deben mezclarse	4
2 Datos y reconstrucción: la primera capa de robustez	7
2.1 Snapshots inmutables y datos puntuales en el tiempo.	7
2.2 Contrato de datos y fuentes candidatas.	8
2.3 De cotizaciones a precios ajustados	9
2.4 SSVI y ausencia de arbitraje estático	11
2.5 Opciones americanas y equivalentes europeos	14
2.6 Extracción de la densidad	15
2.7 Conjunto de superficies plausibles y colas no identificadas.	17
3 Transporte, dinámica y extracción de señal	19
3.1 Representación por cuantiles relativos al forward	19
3.2 Distancias entre distribuciones y cambios firmados	19
3.3 Cadencia, velocidad y aceleración	23
3.4 Reducción de dimensión: componentes funcionales y variables de cola	24
3.5 Filtrado causal con incertidumbre de observación	26
3.6 La propuesta diferenciadora: la innovación	27
3.7 Experimentos concretos	29
3.8 Dinámica de distribuciones como objetos	30
3.9 Límites del transporte	31
4 De la información implícita Q a pronósticos reales P	33
4.1 Por qué Q no es P.	33
4.2 Diseño supervisado y alineación temporal.	34
4.3 Escalera de modelos	34
4.4 Objetivos por horizonte	36
4.5 Combinación de pronósticos	37
4.6 Una referencia estructural: Martin y Wagner	37
5 Regímenes y confianza medible	38
5.1 Detección de cambios de régimen	38

5.2	Cuatro dimensiones de confianza	40
5.3	Calibración y reglas de puntuación	40
5.4	Conformal adaptativo	41
5.5	Abstención	43
6	Decisión de posición y riesgo conjunto	45
6.1	Escenarios conjuntos físicos	45
6.2	El problema costo–riesgo–rendimiento	46
6.3	CVaR: qué mide y qué no	48
6.4	Zona de no operación y estabilidad de la decisión	49
6.5	Fase posterior: optimización robusta	50
6.6	Control predictivo con horizonte móvil	51
6.7	Si se gestionan opciones	51
7	Protocolo de evidencia	53
7.1	Registro previo	53
7.2	Particiones temporales, purga y tamaño efectivo	53
7.3	Comparación incremental	54
7.4	Dos pruebas independientes: pronóstico y política	55
7.5	Sesgo de selección	55
7.6	Intervalos por bloques y evidencia insuficiente	56
7.7	Pruebas de estrés	58
7.8	Regla de avance	58
8	Arquitectura y operación diaria	59
8.1	Componentes	59
8.2	Trazabilidad y reproducibilidad	60
8.3	Calendario diario	60
8.4	Pantalla	61
8.5	Conector de paper y órdenes	62
9	Secuencia de construcción	63
10	Qué priorizar y qué posponer	65
A	Notación	66
B	Glosario	66
C	Decisiones pendientes	67
D	Reproducibilidad de las figuras	67

Resumen ejecutivo

Cada sesión, el sistema hace cinco cosas en un orden fijo. Primero *mide* lo que descuentan las opciones: reconstruye, a partir de cotizaciones de compra y venta, la distribución implícita Q del rendimiento a un plazo constante, con bandas que reflejan los spreads. Después *describe el cambio* respecto de la sesión anterior y separa la parte que ya explicaban el precio, la volatilidad y el mercado. Luego *pronostica* la distribución física $\mathbb{P}$ de los rendimientos posteriores al instante de decisión y comprueba si la información de opciones la mejora. Con ello *decide*, comparando mantener la posición actual con modificarla bajo incertidumbre, costos y riesgo conjunto de la cartera. Por último *registra* todo lo necesario para reproducir la corrida.

i La decisión arquitectónica central

Mantener separadas tres capas: la **medición** Q , la **predicción** $\mathbb{P}$ y la **acción sobre la posición**. Q entra a los modelos como variable, nunca como probabilidad física por decreto; $\mathbb{P}$ se estima con rendimientos realizados y se calibra fuera de muestra; la acción pasa siempre por costos, riesgo y una regla explícita de abstención.

Hipótesis que se quiere contrastar. Las *innovaciones* en la forma de las distribuciones implícitas, una vez descontada la información ya observable en precio, volatilidad y mercado, pueden mejorar los pronósticos de riesgo o de rendimiento. Es una hipótesis que hay que contrastar, no una ventaja demostrada: el documento describe cómo medirla y qué resultados la refutarían. La primera pregunta que conviene responder es si la innovación de las colas, medida con incertidumbre y relativa al mercado, mejora la gestión de una posición existente.

Qué contiene y qué no. Una arquitectura, un conjunto de métodos y un protocolo de evidencia. No contiene resultados empíricos ni modelos entrenados. Las gráficas se construyen con un mundo sintético de parámetros conocidos (apéndice D); su función es mostrar qué calcula cada etapa y qué puede salir mal, no anticipar el desempeño.

Cómo leer este documento. Cada sección corresponde a una etapa del proceso y empieza con una ficha de *entradas, proceso, salidas y controles*. Cinco tipos de recuadro se repiten:

i Idea clave	el concepto que conviene retener de la etapa.
⚠ Qué no concluir	interpretaciones tentadoras que el método no permite.
✓ Criterio para avanzar	condición verificable antes de pasar a la siguiente etapa.
? Pendiente de definir	decisiones del usuario que parametrizan el sistema.
N Nota técnica	detalle de implementación o advertencia matemática.

La figura 1 resume el recorrido completo. Los colores se mantienen en todos los diagramas: azul para la medición Q , naranja para la predicción $\mathbb{P}$ y verde para la acción.




Figura 1. Mapa del proceso diario. Las flechas entre capas son deliberadamente estrechas: de Q a P solo pasan variables candidatas, y de P a la acción solo pasan distribuciones físicas calibradas. El registro y la evaluación de confianza atraviesan todas las etapas.

1 Producto y pregunta de investigación

ENTRADAS	PROCESO	SALIDAS	CONTROLES
Cadenas de opciones con bid/ask, precio del subyacente, posiciones actuales, calendario de resultados y dividendos.	Medir Q , describir su cambio, pronosticar $\mathbb{P}$ y comparar mantener con modificar.	Recomendación con bandas de incertidumbre, o abstención motivada; registro reproducible.	Separación estricta entre Q , $\mathbb{P}$ y acción; ninguna decisión sin calibración ni riesgo conjunto.

1.1 Qué hace el sistema en cada sesión

El producto responde, al inicio de cada sesión, una pregunta operativa concreta: *dado lo que descuentan hoy las opciones y lo que ya se sabe por el precio, ¿conviene mantener la posición o modificarla?* Para llegar a esa respuesta encadena cinco pasos, cada uno con su propia salida verificable:

- 1. Reconstruir lo que descuentan las opciones.** A partir de un *snapshot* de cotizaciones se obtiene una superficie de volatilidad sin arbitraje estático y, de ella, la distribución implícita Q_t del rendimiento a plazo constante, con bandas que reflejan el ancho de los spreads.
- 2. Cuantificar cómo cambió.** Se compara Q_t con Q_{t-1} mediante distancias entre funciones cuantil, cambios firmados por percentil y factores funcionales filtrados.
- 3. Estimar si esa información mejora el pronóstico.** Los cambios — en especial su parte no explicada por la información base — entran como variables candidatas a modelos que pronostican la distribución física $\mathbb{P}$ de rendimientos futuros, evaluados fuera de muestra.
- 4. Comparar mantener con modificar.** Con escenarios conjuntos de la cartera se evalúa el rendimiento esperado, el CVaR y los costos de cada alternativa; los cambios pequeños que no superan costos e incertidumbre se descartan.
- 5. Registrar.** Cada resultado conserva las entradas, versiones, parámetros, hora de corte y motivo de abstención, de modo que la corrida pueda repetirse exactamente.

1.2 Hipótesis principal y cómo se contrasta

Sea $Y_{t,h}$ una variable objetivo medida entre el instante de decisión t y $t+h$ (rendimiento, pérdida o volatilidad realizada), $\mathcal{I}_t^{base}$ la información ya observable en precio, volatilidad y mercado, y ϵ_t la innovación de la distribución implícita definida en la sección 3.6. Con una regla de puntuación propia S (menor es mejor) y dos pronósticos de la *misma familia* de modelos, uno con $\mathcal{I}_t^{base}$ y otro con $\mathcal{I}_t^{base} \cup \{\epsilon_t\}$, se define el diferencial de pérdida

$$d_{t,h} = S(\hat{F}_{t,h}^{base}, Y_{t,h}) - S(\hat{F}_{t,h}^{base+\epsilon}, Y_{t,h}). \quad (1)$$

La hipótesis de trabajo es $H_1 : \mathbb{E}[d_{t,h}] > 0$ fuera de muestra, frente a $H_0 : \mathbb{E}[d_{t,h}] \leq 0$. Se evalúa por separado para cada objetivo y horizonte, con intervalos que respetan la dependencia temporal (sección 7).

⚠ Qué no concluir

- Una mejora en el pronóstico del *riesgo* no implica una mejora en el *signo* del rendimiento, ni al revés; ambas conclusiones son útiles y se reportan por separado.
- Una mejora en el pronóstico no implica una mejor política de posición: puede no pagar sus costos. Son dos pruebas distintas (sección 7.4).
- La hipótesis no presupone una dirección rentable; esa dirección, si existe, se mide.

1.3 Alcance de la primera versión

La primera versión se limita a SPY y entre tres y cinco acciones líquidas, con posiciones en acciones o ETF y sin apalancamiento como supuesto inicial de investigación. Gestionar opciones como posición exigiría una fase específica de valoración y escenarios conjuntos (sección 6.7).

Tabla 1. Alcance de la primera versión.

Elemento	Estado	Comentario
Universo	Propuesto	SPY y 3–5 acciones líquidas; lista definitiva pendiente.
Instrumentos gestionados	Supuesto inicial	Acciones y ETF; opciones como fase aparte.
Apalancamiento	Supuesto de investigación	Sin apalancamiento en la primera versión.
Capital de referencia	Pendiente	50,000; falta definir la moneda.
Posiciones actuales	Pendiente	Necesarias para evaluar “mantener frente a modificar”.
Horizonte de decisión	Pendiente	Candidatos: 1, 5 y 20 sesiones.
Presupuesto de datos	Pendiente	Condiciona la fuente y la historia disponible.

❓ Pendiente de definir

Universo definitivo, moneda de los 50,000, posiciones, horizonte y presupuesto de datos. No son necesarios para *diseñar* el motor, pero sí para *parametrizar* su uso: sin ellos no se pueden fijar límites de concentración, costos ni el benchmark comparable.

1.4 Tres horizontes que no deben mezclarse

El sistema maneja tres escalas de tiempo distintas (figura 2). La **frecuencia de observación** es cada sesión, incluidas las ventanas de apertura. El **horizonte de la distribución implícita** es el plazo de las opciones que se interpolan; inicialmente 30 días calendario y constante, de modo que en $t + 1$ se sigue midiendo a 30 días y no a 29. El **horizonte de decisión y pronóstico** es aquel sobre el que se evalúa el rendimiento de una decisión, por ejemplo 1, 5 y 20 sesiones.




Figura 2. Los tres horizontes. Observar cada sesión no obliga a operar cada sesión; la distribución implícita se mide siempre a 30 días calendario; los pronósticos se evalúan a 1, 5 y 20 sesiones.

La distinción importa porque una distribución a 30 días *no se convierte por simple escalado* en una distribución a una sesión. La varianza no se acumula de manera uniforme: los fines de semana aportan poco, un día de resultados trimestrales aporta mucho, y la estructura temporal de volatilidades rara vez es plana. Las figuras 3 y 4 lo ilustran con un calendario sintético de 30 días que incluye un anuncio de resultados.




Figura 3. Acumulación de varianza en 30 días calendario (datos sintéticos). La escalera muestra una acumulación plausible: casi nada en fines de semana y un salto el día de resultados. La recta es lo que supone un escalado lineal en días calendario.




Figura 4. Desviación estándar de una sesión (datos sintéticos). Las dos primeras barras son los valores del mundo sintético para una sesión normal y para la sesión de resultados; las dos últimas, lo que se obtiene escalando la varianza a 30 días por días calendario o por sesiones. Ningún escalado recupera el riesgo de la sesión de resultados.

Idea clave

El plazo de Q describe qué se mide; el horizonte de decisión describe qué se evalúa. Pasar de uno a otro exige un modelo explícito (calendario de eventos, estructura temporal, supuestos sobre fines de semana), nunca una regla de raíz del tiempo aplicada por defecto.

2 Datos y reconstrucción: la primera capa de robustez

ENTRADAS	PROCESO	SALIDAS	CONTROLES
Cotizaciones bid/ask de cadenas completas, subyacente sincronizado, tasas, dividendos y eventos corporativos, con sellos de tiempo de mercado y de recepción.	Filtrar, estimar forward y descuento, convertir opciones americanas, ajustar una superficie sin arbitraje y extraer la densidad.	Distribución Q_t a plazo constante, cuantiles, bandas de sensibilidad y soporte identificado.	Nada se sobrescribe; densidad no negativa, masa próxima a uno y media igual al forward; colas sin soporte marcadas.

Todo lo que viene después depende de esta etapa. Un error aquí no produce una señal débil: produce una señal falsa con apariencia de precisión. Por eso la reconstrucción se diseña como una cadena de pasos auditables (figura 5), cada uno con un control explícito.




Figura 5. Cadena de reconstrucción de Q . Debajo de cada paso, el control que debe superar antes de alimentar al siguiente.

2.1 Snapshots inmutables y datos puntuales en el tiempo

Cada captura se guarda como un *snapshot inmutable*: nunca se corrige en sitio; una corrección es un registro nuevo con su propia hora de publicación. Esto permite responder, para cualquier instante pasado, la única pregunta válida en un backtest: *¿qué se sabía en ese momento?* La tabla 2 resume los campos mínimos y por qué importan.

Tabla 2. Campos mínimos de cada snapshot.

Campo	Por qué importa
Bid, ask y tamaños	La banda $[b, a]$ es la observación; el mid es solo un punto interior.
Hora de mercado y de recepción	Separan cuándo ocurre un dato de cuándo se conoce (figura 6).
Subyacente sincronizado	Un desfase de segundos contamina el forward y la volatilidad implícita.
Strike, vencimiento, estilo, multiplicador	Definen el contrato; el estilo americano exige conversión.
Dividendos, tasas y eventos corporativos	Determinan forward, descuento y ajustes de contrato.
Revisiones y open interest	Se guardan con su hora efectiva de disponibilidad, no con la del dato.




Figura 6. Hora en que ocurre un dato frente a hora en que se conoce. En el corte de las 09:45 solo son utilizables las flechas que llegan a la línea inferior antes del corte: la cotización en tiempo real, el open interest del cierre anterior y, con una fuente retrasada, lo ocurrido a las 09:30. La revisión publicada a las 11:05 no existe para esa decisión aunque se refiera a un dato anterior.

2.2 Contrato de datos y fuentes candidatas

Antes de adquirir historia extensa conviene validar una muestra contra un contrato explícito. El primer contrato debe demostrar, como mínimo:

- cadenas *completas*, incluidos contratos ya vencidos, y paginación sin huecos;
- cobertura histórica *a la hora de decisión*, no solo al cierre;
- acceso a cotizaciones de compra y venta. Las barras OHLC de operaciones no sustituyen una cadena contemporánea de cotizaciones: una operación puede ser antigua, aislada o fuera del spread;
- sellos de tiempo suficientes para reconstruir la sincronía con el subyacente.

Tabla 3. Fuentes candidatas según la documentación citada en la propuesta. Cobertura, licencia y precio deben cotizarse; no se asumen.

Fuente	Lo que documenta	Uso previsto
Alpaca	Históricos de opciones desde febrero de 2024; el feed indicativo modifica cotizaciones (Alpaca, s.f.).	Explorar la integración. No se asume suficiente para estudiar cambios diarios pequeños de distribución.
Cboe DataShop	Snapshots NBBO por intervalos con historia desde enero de 2012; entrega intradía estándar con 15 minutos de retraso (Cboe DataShop, s.f.).	Investigación histórica. Una decisión en apertura exige una fuente con latencia adecuada o retrasar explícitamente la decisión.

✓ **Criterio para avanzar**

Cadenas reconstruibles en el instante de decisión, con cobertura y costo conocidos, validadas sobre una muestra antes de comprar historia extensa.

2.3 De cotizaciones a precios ajustados

Forward y descuento. Para opciones europeas, la paridad put–call $C(K) - P(K) = D(F - K)$ permite estimar D y F por regresión de $C - P$ sobre K cerca del dinero. Con opciones americanas con dividendos la paridad es solo una desigualdad; entonces D proviene de la curva de tasas y F del subyacente, las tasas y los dividendos esperados, y la paridad se usa como control de calidad.

Selección y filtros. Se trabaja con opciones fuera del dinero (puts bajo el forward, calls por encima), más líquidas y con menor valor intrínseco. Se excluyen, registrando el motivo, las cotizaciones cruzadas, rancias o con spread anómalo. Una cotización con bid nulo no se descarta sin más: su ask sigue siendo una cota superior útil, aunque no identifica la cola (figura 7).




Figura 7. Cotizaciones OTM a 30 días en el mundo sintético. Cada segmento vertical es un intervalo bid-ask; los triángulos son cotizaciones con bid nulo, que solo acotan el precio por arriba. La curva es el ajuste SSVI en espacio de precios.

Ajuste en espacio de precios. El midpoint no es una verdad exacta: cualquier precio dentro de $[b_i, a_i]$ es compatible con la cotización. Por eso el residuo de cada contrato es su *distancia a la banda*, medida en medios spreads $s_i = \max\{(a_i - b_i)/2, \text{tick}\}$:

$$\min_{\vartheta \in \Theta} \sum_i \omega_i \left[\frac{(b_i - C_i(\vartheta))^+ + (C_i(\vartheta) - a_i)^+}{s_i} \right]^2 + \eta \sum_i \omega_i \left[\frac{C_i(\vartheta) - m_i}{s_i} \right]^2 + \mathcal{R}(\vartheta), \quad (2)$$

donde $C_i(\vartheta)$ es el precio del modelo, m_i el mid, η un peso pequeño que solo desempata entre precios igualmente compatibles y $\mathcal{R}$ una regularización, por ejemplo hacia el ajuste de la sesión anterior. Ajustar en precios y no en volatilidades evita dar peso excesivo a las alas, donde un spread de un tick equivale a varios puntos de volatilidad (figura 8).




Figura 8. La misma cadena en volatilidad implícita. Los intervalos se ensanchan en las alas y las cotizaciones con bid nulo solo dan cotas superiores cada vez más altas: en volatilidad, esas cotas parecen “información” sobre la cola derecha que en realidad no existe.




Figura 9. Pérdida de una cotización con bid 1.00 y ask 1.20. La pérdida cuadrática al mid penaliza precios perfectamente compatibles; la distancia a la banda es casi nula dentro del intervalo y crece fuera de él.

2.4 SSVI y ausencia de arbitraje estático

El modelo base es SSVI (Gatheral y Jacquier, 2014), que describe la varianza implícita total $w = \sigma^2 T$ como función del log-moneyness $k = \ln(K/F)$ y de la varianza total en el dinero θ_T de cada

vencimiento:

$$w(k, \theta_T) = \frac{\theta_T}{2} \left\{ 1 + \rho \varphi(\theta_T) k + \sqrt{(\varphi(\theta_T) k + \rho)^2 + 1 - \rho^2} \right\}, \quad \varphi(\theta) = \frac{\eta}{\theta^\gamma (1 + \theta)^{1-\gamma}}. \quad (3)$$

El parámetro ρ controla la asimetría, φ la curvatura y el peso de las alas, y θ_T el nivel por vencimiento. Una SVI sin restricciones no garantiza ausencia de arbitraje; SSVI admite condiciones suficientes sencillas:

- **Calendario:** θ_T no decreciente en T y $0 \leq \partial_\theta(\theta \varphi(\theta)) \leq \rho^{-2}(1 + \sqrt{1 - \rho^2}) \varphi(\theta)$.
- **Mariposa:** $\theta \varphi(\theta)(1 + |\rho|) < 4$ y $\theta \varphi(\theta)^2(1 + |\rho|) \leq 4$.
- **Función de potencia:** con $0 < \gamma \leq 1/2$ y $\eta(1 + |\rho|) \leq 2$ se cumplen ambas familias de condiciones, siempre que θ_T sea no decreciente.

La primera condición de mariposa es coherente con la fórmula de momentos de [Lee \(2004\)](#): la pendiente asintótica de la varianza total no puede superar 2.

N Restricciones por construcción

En la implementación de referencia las restricciones no se verifican a posteriori: se imponen con una reparametrización sin restricciones, $\rho = 0.999 \tanh(a)$, $\gamma = \frac{1}{2} \sigma(b)$, $\eta = 2\sigma(c)/(1 + |\rho|)$ y $\theta_i = \sum_{j \leq i} e^{d_j}$, con σ la función logística. Cuando el ajuste queda en la frontera de la región suficiente (como en la figura 11), conviene registrarlo: la región es suficiente, no necesaria, y una restricción activa puede estar sesgando la forma.




Figura 10. Rebanadas de varianza total ajustadas para 7, 30, 60 y 91 días en el mundo sintético. No se cruzan: esa es la forma gráfica de la ausencia de arbitraje de calendario.




Figura 11. Región suficiente de la función de potencia en el plano $(|\rho|, \eta)$ con $\gamma \leq 1/2$. El cuadrado es el valor verdadero del mundo sintético; el círculo, el ajuste, que queda en la frontera.

La prueba directa de mariposa usa la función g de Durrleman, en la forma de [Gatheral y Jacquier \(2014\)](#): con w' y w'' derivadas respecto de k ,

$$g(k) = \left(1 - \frac{k w'}{2w}\right)^2 - \frac{(w')^2}{4} \left(\frac{1}{w} + \frac{1}{4}\right) + \frac{w''}{2}, \quad (4)$$

y la densidad de $x = \ln(S_T/F)$ es $p(k) = g(k) (2\pi w)^{-1/2} \exp\{-d_-(k)^2/2\}$ con $d_-(k) = -k/\sqrt{w} - \sqrt{w}/2$. Una rebanada tiene densidad no negativa si y solo si $g \geq 0$ (figura 12).




Figura 12. Función $g(k)$ para una rebanada SSVI restringida y para una SVI sin restricciones con parámetros publicados como contraejemplo en [Gatheral y Jacquier \(2014\)](#). Donde $g < 0$ la densidad implícita sería negativa: un arbitraje de mariposa.

Comparación independiente. Como contraste se ajusta, sin forma paramétrica de volatilidad, una densidad discreta $q_j \geq 0$ sobre una malla x_j :

$$C(K) = D \sum_j q_j (x_j - K)^+, \quad \sum_j q_j = 1, \quad \sum_j q_j x_j = F. \quad (5)$$

Cualquier $q \geq 0$ produce precios decrecientes y convexos en K , y las dos igualdades fijan la masa y la media del forward. Con un precio auxiliar $p_i \in [b_i, a_i]$ por cotización, la pérdida por banda se vuelve un problema de mínimos cuadrados lineales con cotas, convexo y rápido de resolver, al que se añade una penalización de suavidad sobre q . Donde SSVI y este ajuste discrepan hay *riesgo de modelo*, no un dato (Aït-Sahalia y Lo, 1998).

2.5 Opciones americanas y equivalentes europeos

SPY y las acciones individuales tienen opciones americanas; la identidad de extracción de la sección 2.6 es europea. Hay dos caminos: convertir cada cotización en un equivalente europeo con un modelo que incluya ejercicio anticipado y dividendos, o excluir las observaciones donde la conversión sea demasiado incierta. La conversión estándar (*desamericanización*) tiene dos pasos: invertir el precio americano con un árbol binomial (Cox et al., 1979) o diferencias finitas con dividendos discretos para obtener una volatilidad, y valorar con ella la opción europea equivalente (Burkovska et al., 2018).

Seleccionar opciones fuera del dinero reduce el problema pero no lo elimina (figuras 13 y 14). El error de conversión depende del modelo y de los dividendos supuestos; por eso se contrasta dentro de los escenarios de incertidumbre (sección 2.7) en lugar de tratarlo como exacto.




Figura 13. Sesgo, en puntos de volatilidad, de tratar puts americanas como europeas (líneas continuas), comparado con medio spread expresado en volatilidad (discontinuas). A 91 días el sesgo de puts cerca del dinero ya es comparable con medio spread, aunque estén fuera del dinero.




Figura 14. Lo mismo para calls con un dividendo en efectivo dentro del plazo. Las calls dentro del dinero antes de la fecha ex-dividendo tienen una prima de ejercicio anticipado grande; las calls fuera del dinero apenas se ven afectadas.

2.6 Extracción de la densidad

Para calls europeas y descuento determinista $D(t, T)$ se cumple (Breedon y Litzenberger, 1978)

$$q_t^Q(K, T) = \frac{1}{D(t, T)} \frac{\partial^2 C_t(K, T)}{\partial K^2}, \quad Q_t(S_T \leq K) = 1 + \frac{1}{D(t, T)} \frac{\partial C_t(K, T)}{\partial K}. \quad (6)$$

La identidad se aplica al *precio ajustado*, nunca a diferencias de cotizaciones crudas: una segunda derivada amplifica el ruido de redondeo y de spread hasta producir densidades negativas (figuras 15 y 16).




Figura 15. Segundas diferencias de los mid crudos (mundo sintético con strikes cada punto). La curva discontinua es la densidad verdadera, desconocida en la práctica; los puntos rojos son valores negativos, imposibles para una densidad.




Figura 16. La misma identidad sobre precios ajustados. La densidad SSVI integra 0.9998 en la malla y su media es $1.0001F$; el ajuste monótono–convexo, independiente, coincide en el cuerpo.

Los controles mínimos de cada densidad son tres, y se registran con su valor numérico:

1. **No negatividad** en toda la malla evaluada.
2. **Masa próxima a uno.** La masa que falta está en colas sin strikes y se reporta; no se redistribuye en silencio.
3. **Primer momento compatible con el forward:** $\mathbb{E}^Q[S_T] = F$.

También se documentan el error numérico (paso de la malla, diferencias finitas) y la sensibilidad a la extrapolación de strikes extremos.

⚠ Qué no concluir

La media de Q está fijada por el forward. No es una expectativa de rentabilidad real y no contiene, por construcción, ninguna opinión del mercado sobre el signo del rendimiento esperado.

2.7 Conjunto de superficies plausibles y colas no identificadas

Un solo ajuste oculta cuánto podría variar la distribución sin dejar de ser compatible con las cotizaciones. Por eso se mantiene un *conjunto* de superficies plausibles, coherentes con los spreads y las restricciones: se sortean precios objetivo dentro de cada $[b_i, a_i]$, se reajustan ambos métodos y se repite con supuestos alternativos de dividendos y desamericanización. De ese conjunto salen bandas para cuantiles y probabilidades de cola (figuras 17 y 18).




Figura 17. Bandas de densidades compatibles con los spreads, en escala logarítmica. La banda SSVI es estrecha incluso donde no hay strikes fiables (más allá de los cuadrados): esa precisión la pone la forma paramétrica, no los datos. El ajuste monótono–convexo muestra cuánto se ignora realmente en las colas.




Figura 18. Ancho de la banda de sensibilidad de cada cuantil. Los cuadrados marcan el rango identificado $[u_{\min}, u_{\max}]$, definido por los strikes fiables más extremos; fuera de él los cuantiles se reportan como no identificados.

⚠ Qué no concluir

Estas bandas son de *sensibilidad*: describen qué distribuciones son compatibles con los datos y los supuestos. No son intervalos de confianza estadísticos, porque no hay un modelo de observación que lo justifique. Si falta soporte en una cola, se marca como no identificada; no se rellena con precisión artificial.

✅ Criterio para avanzar

Coherencia matemática (controles de la sección 2.6 superados en cada sesión) y estabilidad de cuantiles y colas frente a perturbaciones plausibles de spreads y supuestos.

3 Transporte, dinámica y extracción de señal

ENTRADAS	PROCESO	SALIDAS	CONTROLES
Distribuciones Q_t a plazo constante con bandas y soporte identificado; información base de precio, volatilidad y mercado.	Representar por cuantiles, medir distancias y cambios firmados, reducir dimensión, filtrar causalmente y calcular la innovación.	Serie de distancias, factores filtrados con incertidumbre, variables de cola e innovaciones.	Todo ajuste usa solo el pasado; reconstrucciones ordenadas; medidas recortadas declaradas como tales.

3.1 Representación por cuantiles relativos al forward

Cada distribución se representa por su función cuantil de rendimientos logarítmicos relativos al forward, a plazo constante τ :

$$x_t(u, \tau) = F_{Q_t}^{-1}(u), \quad \text{con } x = \ln(S_{t+\tau}/F_{t,\tau}), \quad u \in (0, 1). \quad (7)$$

Medir respecto del forward retira el desplazamiento puramente mecánico del nivel de precios: si el subyacente sube 1 % y nada más cambia, $x_t(u)$ no se mueve. La vista en precios absolutos se conserva por separado para interpretar la posición. El plazo constante se obtiene interpolando θ_T entre vencimientos listados; como θ interpolado linealmente sigue siendo no decreciente, se preserva la ausencia de arbitraje de calendario. Por construcción $\mathbb{E}^Q[e^x] = 1$.

3.2 Distancias entre distribuciones y cambios firmados

En una dimensión, el transporte óptimo entre dos distribuciones es el *reordenamiento monótono*: cada cuantil se desplaza a su homólogo, $T = F_t^{-1} \circ F_{t-1}$ (Peyré y Cuturi, 2019). La distancia de Wasserstein de orden 2 se calcula entonces directamente sobre las funciones cuantil:

$$W_2^2(Q_t, Q_{t-1}) = \int_0^1 [x_t(u) - x_{t-1}(u)]^2 du, \quad W_1(Q_t, Q_{t-1}) = \int_0^1 |x_t(u) - x_{t-1}(u)| du. \quad (8)$$

W_1 es menos sensible que W_2 a desplazamientos extremos y equivale al área entre las dos funciones de distribución. Para familias de posición y escala, $W_2^2 = (\Delta\mu)^2 + (\Delta\sigma)^2$, lo que ayuda a leer su magnitud. Si solo existe cobertura fiable del 5 % al 95 %, se reporta la versión recortada $W_{2,[a,b]}^2 = \int_a^b [\Delta x(u)]^2 du$ con su rango, nunca como distancia de toda la distribución.




Figura 19. Distribución implícita a 30 días antes y después de un choque común en el mundo sintético: más dispersión y una cola izquierda más larga.




Figura 20. Mapa de transporte óptimo entre las dos sesiones de la figura 19: cada cuantil anterior (eje horizontal) se envía al mismo cuantil posterior (eje vertical). La pendiente mayor que uno indica más dispersión; la diagonal sería “sin cambio”.




Figura 21. Funciones cuantil antes y después del choque. W_2 es la distancia L^2 entre ellas; la leyenda compara la versión completa, la recortada a $[0.05, 0.95]$ y W_1 .

La magnitud sola no dice qué cambió. Por eso se registran también los *cambios firmados* $\Delta x_t(u)$ en percentiles clave, que distinguen deformaciones con distancias parecidas (figuras 22 y 23).




Figura 22. Perfil firmado de tres deformaciones arquetípicas de una misma distribución: más dispersión, cola izquierda más pesada y cambio solo en las alas. Un $\Delta x < 0$ con $u < 1/2$ significa que la cola izquierda se alarga.




Figura 23. Distancias de los tres arquetipos. W_2 pesa más el cambio en las alas que W_1 ; la versión recortada casi no lo ve. Ninguna cifra aislada identifica el tipo de cambio.




Figura 24. Mapa temporal de cuantiles: desviación de cada $x_t(u)$ respecto de su media de entrenamiento, por sesión. El choque común de la sesión 170 alarga ambas colas; las columnas en blanco son snapshots faltantes.




Figura 25. Distancias entre sesiones consecutivas. Los puntos rojos son sesiones con spreads amplios, donde parte de la distancia es ruido de ajuste y no cambio de distribución: una razón para filtrar antes de interpretar.

3.3 Cadencia, velocidad y aceleración

Las velocidades se definen sobre una cadencia fija y con diferencias hacia atrás, $v_t(u) = x_t(u) - x_{t-1}(u)$, en canales separados: *cierre-apertura* y *apertura-apertura*. Fines de semana, feriados y ventanas intradía son intervalos de tipo distinto y se etiquetan como tales; no se mezclan como si fueran idénticos ni se escalan por tiempo calendario sin un modelo. La aceleración $a_t(u) = v_t(u) - v_{t-1}(u)$ queda como candidata secundaria por una razón aritmética: si cada x_t tiene ruido de medición independiente de varianza σ^2 , la velocidad hereda $2\sigma^2$ y la aceleración $6\sigma^2$ (figuras 26 y 27).




Figura 26. Cociente entre la varianza de la señal y la del ruido de medición para el nivel, la velocidad y la aceleración de un factor sintético. Diferenciar multiplica la desviación estándar del ruido por $\sqrt{2}$ y $\sqrt{6}$ mientras la señal se vuelve más pequeña.




Figura 27. Aceleración latente frente al ruido de medición que contiene la aceleración observada: fuera del choque son de magnitud comparable.

3.4 Reducción de dimensión: componentes funcionales y variables de cola

Para resumir la forma se aplica un análisis de componentes principales funcional a los cuantiles centrados, con pesos de cuadratura en la malla de u y ajustado *únicamente con datos de entrenamiento*:

$$x_t(u) \approx \bar{x}(u) + \sum_{j=1}^J s_{tj} \phi_j(u), \quad s_{tj} = \int_0^1 [x_t(u) - \bar{x}(u)] \phi_j(u) du. \quad (9)$$

Se conservan factores suficientes para explicar dispersión y asimetría. Pero una PCA global puede ignorar las colas precisamente porque explican poca varianza total (figuras 28 y 29); por eso se añaden variables explícitas de cola, por ejemplo el ancho de la cola izquierda $x_t(0.10) - x_t(0.01)$ dentro del rango identificado, o la asimetría por cuantiles $[x_t(0.9) + x_t(0.1) - 2x_t(0.5)] / [x_t(0.9) - x_t(0.1)]$.




Figura 28. Primeras autofunciones de la PCA funcional, estimadas solo con las sesiones de entrenamiento del mundo sintético. La primera captura dispersión; la segunda, asimetría; la tercera, las alas.




Figura 29. Varianza explicada por componente, en escala logarítmica. La componente de colas explica una fracción ínfima de la varianza total aunque pueda ser la más relevante para el riesgo.

Toda reconstrucción debe seguir siendo una función cuantil válida, es decir, creciente en u . Con pocos factores eso no está garantizado; se corrige con el reordenamiento creciente (Chernozhukov

et al., 2010), que no aumenta la distancia L^p a la función verdadera, o se trabaja en una transformación que garantice monotonía, como el logaritmo de la densidad cuantílica (Petersen y Müller, 2016).

3.5 Filtrado causal con incertidumbre de observación

Los factores observados cada sesión mezclan cambio real y error de ajuste. Se filtran con un modelo de estado lineal y el filtro de Kalman (Kalman, 1960):

$$f_t = Af_{t-1} + \eta_t, \quad \eta_t \sim \mathcal{N}(0, Q); \quad y_t = f_t + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, R_t), \quad (10)$$

donde la varianza de observación R_t depende de la calidad de la sesión: ancho de spreads, número de strikes válidos y error de ajuste. Con calidad baja, el filtro confía menos en la observación y más en la dinámica. Si falta el snapshot, solo se ejecuta la predicción. Los parámetros (A, Q, R_0) se estiman por máxima verosimilitud con datos de entrenamiento.

Solo se usa el *filtro*, que emplea información hasta t . Un suavizador que incorpore observaciones futuras produce series más limpias y backtests inválidos. La comparación obligada es con una media exponencial (EWMA) y con la persistencia: un filtro más complejo puede borrar señales rápidas (figuras 30 y 31).




Figura 30. Filtrado del primer factor en el mundo sintético. El filtro de Kalman, con R_t mayor en las sesiones de spreads amplios, sigue al factor latente; la EWMA suaviza el ruido pero llega tarde al choque de la sesión 170.





Figura 31. Error frente al factor latente por ventana de evaluación. Ningún método domina: la persistencia es casi tan buena con calidad normal, el filtro ayuda cuando los spreads son amplios y la EWMA falla tras el choque.

3.6 La propuesta diferenciadora: la innovación

Buena parte del cambio diario de la distribución implícita es predecible con información que ya está en el precio: si el mercado cae, la cola izquierda suele alargarse. Lo potencialmente informativo es lo que *no* se explica así. Se define la innovación

$$\epsilon_t(u) = \Delta x_t(u) - \hat{\mathbb{E}}[\Delta x_t(u) | \mathcal{I}_t^{base}], \quad (11)$$

donde $\mathcal{I}_t^{base}$ incluye el retorno ya observado del subyacente, su volatilidad, el movimiento de mercado y sector, el gap de apertura y el calendario conocido de resultados y dividendos (figura 32). El modelo de expectativa se entrena *solo con fechas anteriores*; para una acción, además, se calcula la innovación relativa al mercado, $\epsilon_t^A - \beta \epsilon_t^M$, para separar señal idiosincrática de choque común.



La innovación no prueba información privada ni causalidad: es un candidato cuyo valor predictivo se mide fuera de muestra.

Figura 32. Construcción de la innovación. La resta se hace con una expectativa estimada exclusivamente con el pasado.




Figura 33. Cambio observado del cuantil 5% de la acción A frente al esperado dado la información base. La distancia vertical a la diagonal es la innovación. El evento idiosincrático (círculo) alarga la cola sin movimiento de precio; el choque común (cuadrado) se explica solo en parte.




Figura 34. Innovación del mercado e innovación de la acción A relativa al mercado. En la versión relativa el choque común casi se cancela y el evento propio de A sobresale.

⚠ Qué no concluir

La innovación no prueba información privada ni causalidad. Es una variable candidata para pronosticar rendimientos *posteriores* al instante de decisión, y su utilidad se mide fuera de muestra con el protocolo de la sección 7. En el mundo sintético de estas figuras, por diseño, la innovación no predice nada: solo se muestra cómo se calcula.

3.7 Experimentos concretos

La tabla 4 lista los primeros experimentos. En ninguno se asume una dirección rentable antes de medirla.

Tabla 4. Primeros experimentos sobre la señal.

Experimento	Variable	Pregunta
Cola izquierda frente al mercado	$\epsilon_t^A(u) - \beta \epsilon_t^M(u)$ para $u \leq 0.10$	¿Aporta la deformación idiosincrática de la cola a los pronósticos de riesgo o rendimiento?
Deformación entre plazos	Diferencia de $\Delta x_t(u) / \sqrt{\tau}$ entre 7, 30 y 60 días	¿Distingue eventos de corto plazo de choques de nivel? Requiere cotizaciones suficientes en cada plazo.
Persistencia	Autocorrelación de ϵ_t y su vida media	¿La innovación se revierte, persiste o se incorpora al precio?
Idiosincrático frente a común	Descomposición de ϵ_t^A en componente de mercado y residual	¿Qué parte, si alguna, contiene información que no está en el mercado?




Figura 35. Cambio de cuantiles por plazo, normalizado por $\sqrt{\tau}$, ante un choque común de volatilidad: el perfil es parecido en los tres plazos, algo mayor en el corto.




Figura 36. Ante un evento dentro de los próximos 7 días, la distribución a 7 días se deforma mucho más que las de 30 y 60: la diferencia entre plazos es la huella del evento.

3.8 Dinámica de distribuciones como objetos

Como modelo avanzado se compara la autorregresión de factores con una autorregresión en espacio de Wasserstein (Zhang et al., 2022). La idea: el espacio de distribuciones no es lineal, pero alrededor del baricentro de Wasserstein $\bar{Q}$ tiene un espacio tangente que sí lo es. En una dimensión el baricentro es el promedio de funciones cuantil, $\bar{x}(u) = \mathbb{E}[x_t(u)]$, y el “logaritmo” de Q_t es simplemente $v_t(u) = x_t(u) - \bar{x}(u)$. Se ajusta un autorregresivo sobre v_t y se regresa a funciones cuantil, proyectando cuando el pronóstico deja de ser creciente (figura 37).




Figura 37. Autorregresión en el espacio tangente del baricentro. En una dimensión el espacio tangente coincide con el de cuantiles centrados, así que la PCA funcional de la sección 3.4 y este modelo son parientes cercanos: difieren en cómo parametrizan la dinámica.

Esta familia permite pronosticar distribuciones como objetos. Su uso aquí es una adaptación de investigación: no demuestra capacidad para anticipar el precio de las acciones.

3.9 Límites del transporte

El transporte óptimo entre marginales *no* identifica un proceso temporal del precio ni probabilidades de tocar un stop. Las figuras 38 y 39 lo muestran con 20 000 trayectorias: ambas tienen exactamente las mismas distribuciones a 30 y 60 días, pero en una se reordenan como si cada cuantil siguiera su propio camino.




Figura 38. Trayectorias de una difusión (muestra de 70). La probabilidad de tocar un stop en 90 antes de 60 días es la que indica el título.




Figura 39. Las mismas marginales leídas como trayectorias del mapa monótono: la probabilidad de tocar el stop cae casi a la mitad. Las marginales no deciden cuál de las dos es la correcta.

i Idea clave

El campo de transporte es una descripción geométrica de cómo cambió la distribución, no una ley física que deba imponerse al mercado. Las probabilidades de trayectoria (stops, barreras, máximos) requieren un modelo dinámico explícito y su propia validación.

✓ Criterio para avanzar

Separar ruido de cambios persistentes con filtros causales; todas las series de esta etapa calculables sin información futura y reproducibles con el snapshot de cada sesión.

4 De la información implícita Q a pronósticos reales P

ENTRADAS	PROCESO	SALIDAS	CONTROLES
Variables de Q (factores, colas, innovaciones), información base y rendimientos realizados después de cada snapshot.	Entrenar modelos supervisados por objetivo y horizonte, corregir cruces de cuantiles y combinar.	Distribuciones físicas $\mathbb{P}$ por horizonte: cuantiles, probabilidades de evento y volatilidad esperada.	Etiquetas alineadas con el instante de decisión; mejora incremental medida dentro de una misma familia de modelos.

4.1 Por qué Q no es P

Q y $\mathbb{P}$ son dos distribuciones distintas del mismo rendimiento. Q es la que hace coherentes los precios de las opciones; $\mathbb{P}$ describe con qué frecuencia ocurren las cosas. Las une un núcleo de valoración (factor estocástico de descuento proyectado) m :

$$q(x) = \frac{m(x) p(x)}{\mathbb{E}^{\mathbb{P}}[m]}. \quad (12)$$

Sin supuestos adicionales m no está identificado: la misma q es compatible con muchas parejas (m, p) . Los intentos de “recuperar” $\mathbb{P}$ a partir de Q requieren supuestos fuertes (Ross, 2015) cuya validez está en discusión (Borovička et al., 2016). Para índices bursátiles se documenta, en promedio, una prima de varianza: la dispersión implícita tiende a superar a la realizada (Carr y Wu, 2009). La figura 40 ilustra un supuesto de ese tipo y la figura 41 el núcleo que implicaría.




Figura 40. Una distribución Q y una $\mathbb{P}$ supuesta para el mismo activo. La media de Q está fijada por el forward; la de $\mathbb{P}$ incorpora una prima. La cola izquierda de Q es más pesada. Ilustrativo: la relación real entre ambas es lo que se estima, no lo que se supone.




Figura 41. Cociente q/p implícito en el supuesto de la figura 40. Otra elección de p daría otro cociente con la misma q : por eso $\mathbb{P}$ se estima con rendimientos realizados y no se deduce de Q .

4.2 Diseño supervisado y alineación temporal

Los modelos se entrenan con rendimientos efectivamente realizados *después* de cada snapshot. Las variables de Q entran como regresores; no se etiquetan como probabilidades físicas por decreto. La etiqueta de horizonte h solo existe en $t + h$, y hasta entonces no puede usarse para entrenar, calibrar ni actualizar intervalos (figura 42).




Figura 42. Alineación temporal. Las variables se calculan con información hasta el corte; la etiqueta es el rendimiento posterior al instante de decisión y madura al final de su horizonte.

4.3 Escalera de modelos

El orden propuesto va de lo simple a lo flexible, y cada peldaño debe ganarle al anterior fuera de muestra para justificar su complejidad (figura 43):

1. **Referencia histórica con volatilidad dinámica:** cuantiles de residuos estandarizados históricos escalados por una volatilidad EWMA o GARCH.

2. **Regresión cuantílica regularizada** (Koenker y Bassett, 1978): para cada nivel τ ,

$$\hat{\beta}_\tau = \arg \min_{\beta} \sum_t \rho_\tau(y_t - z_t^\top \beta) + \lambda \|\beta_{-0}\|_1, \quad \rho_\tau(e) = e(\tau - \mathbb{1}\{e < 0\}), \quad (13)$$

un programa lineal (figura 44).

3. **Boosting cuantílico** con la misma pérdida y corrección de cruces.

4. **NGBoost** (Duan et al., 2020), que estima con gradiente natural los parámetros de una familia de distribuciones condicional. La familia y sus colas se eligen por validación, sin imponer normalidad por comodidad.




Figura 43. Escalera de modelos IP, combinación y objetivos por horizonte.




Figura 44. Pérdida cuantílica para $\tau = 0.05, 0.50$ y 0.95 . Su asimetría es la que hace que el minimizador sea el cuantil τ .

Estimar cada cuantil por separado puede producir *cruces*: en una zona de extrapolación el cuantil del 25 % queda por debajo del 5 % (figura 45). El reordenamiento creciente de los cuantiles

estimados en cada punto corrige el problema sin empeorar la estimación (Chernozhukov et al., 2010) (figura 46).




Figura 45. Regresiones cuantílicas estimadas por separado con 70 observaciones sintéticas. Fuera del rango observado de la variable, dos cuantiles se cruzan (punto rojo).




Figura 46. Los mismos cuantiles después de reordenarlos en cada valor de la variable: siempre crecientes en τ .

4.4 Objetivos por horizonte

Cada objetivo tiene su pérdida y se entrena por separado. La información de opciones podría mejorar el riesgo sin mejorar el signo del rendimiento; ambas conclusiones son útiles y se muestran por separado.

Tabla 5. Objetivos, pronósticos y pérdidas. Horizontes candidatos: 1, 5 y 20 sesiones.

Objetivo	Pronóstico	Pérdida y diagnóstico
Rendimiento	Distribución completa; mediana	CRPS; pinball en $\tau = 0.5$; calibración de cuantiles
Superar costos	Probabilidad de que el rendimiento neto sea positivo	Brier y log score; diagrama de fiabilidad
Cuantiles de pérdida	$q_{0.05}$ y $q_{0.10}$	Pinball; cobertura y ancho de intervalos
Volatilidad futura	Varianza realizada esperada	QLIKE, robusta a proxies ruidosos (Patton, 2011)

4.5 Combinación de pronósticos

Los pronósticos se combinan con pesos no negativos que suman uno, aprendidos en validación temporal —por ejemplo, minimizando el CRPS de la mezcla o la pérdida cuantílica del promedio de cuantiles— y se comparan siempre con pesos iguales, que en la práctica son difíciles de superar (Timmermann, 2006). El acuerdo entre modelos parecidos no es evidencia independiente: si comparten variables y ventana de entrenamiento, sus errores están correlacionados.

4.6 Una referencia estructural: Martin y Wagner

Martin y Wagner (2019) proponen una expresión del rendimiento esperado de una acción a partir de índices de varianza implícita, derivada de Martin (2017):

$$\frac{\mathbb{E}_t[R_{i,t+1}] - R_{f,t+1}}{R_{f,t+1}} = \text{SVIX}_t^2 + \frac{1}{2} \left(\text{SVIX}_{i,t}^2 - \overline{\text{SVIX}_t^2} \right), \quad (14)$$

donde SVIX_t es el del mercado, $\text{SVIX}_{i,t}$ el de la acción y $\overline{\text{SVIX}_t^2}$ el promedio ponderado por valor de la sección transversal. Queda como referencia estructural si se dispone de esos insumos de mercado y de sección transversal; no sustituye la calibración diaria descrita arriba.

⚠ Qué no concluir

Ni la (14) ni ningún modelo de esta sección convierte a Q en P. Todo pronóstico P se valida con rendimientos realizados y con las reglas de puntuación de la sección 5.3.

✅ Criterio para avanzar

Mejora incremental fuera de muestra respecto de la referencia, dentro de la misma familia de modelos, o una delimitación honesta de dónde no hay utilidad.

5 Regímenes y confianza medible

ENTRADAS	PROCESO	SALIDAS	CONTROLES
Errores de pronóstico ya madurados, factores filtrados, indicadores de calidad de datos y de ajuste.	Detectar cambios de comportamiento, medir calibración, construir intervalos adaptativos y decidir si abstenerse.	Probabilidad de cambio reciente, métricas de calibración, intervalos con nivel efectivo y estado de confianza por dimensión.	Calibración en un tramo temporal separado; actualización solo con resultados madurados; abstención con motivo registrado.

5.1 Detección de cambios de régimen

La detección bayesiana en línea de puntos de cambio (Adams y MacKay, 2007) mantiene la distribución posterior de la *longitud de corrida* r_t , el número de sesiones desde el último cambio. Con una probabilidad de riesgo H por sesión y la predictiva $\pi_t^{(r)} = p(x_t | r_{t-1} = r, x^{(r)})$ calculada con los datos de la corrida,

$$P(r_t = r + 1, x_{1:t}) = P(r_{t-1} = r, x_{1:t-1}) \pi_t^{(r)} (1 - H), \quad (15)$$

$$P(r_t = 0, x_{1:t}) = \sum_r P(r_{t-1} = r, x_{1:t-1}) \pi_t^{(r)} H. \quad (16)$$

Con una previa normal–gamma inversa, la predictiva es una t de Student y la recursión es exacta. Se aplica sobre errores de pronóstico o factores, y se compara primero con un detector simple por umbral (figuras 47 a 49).




Figura 47. Errores estandarizados de pronóstico en un mundo sintético con un cambio de varianza en la sesión 160, y alarmas de un detector por umbral (dos de las últimas cinco sesiones con $|z| > 2.5$).




Figura 48. Posterior de la longitud de corrida de BOCPD en escala logarítmica. Tras el cambio, la masa colapsa a corridas cortas y vuelve a crecer desde cero.




Figura 49. Probabilidad posterior de que haya ocurrido un cambio en las últimas diez sesiones. Es alta justo después del cambio verdadero y baja el resto del tiempo.

⚠ Qué no concluir

Una probabilidad alta de cambio de régimen dice que el comportamiento reciente difiere del aprendido; no es una probabilidad de caída del precio. Su uso natural es degradar la confianza y ampliar la incertidumbre, no generar señales direccionales.

5.2 Cuatro dimensiones de confianza

La salida del sistema distingue cuatro fuentes de duda que no deben mezclarse en un solo número (figura 50). Un alto número de contratos observados no equivale a muchas sesiones independientes: cien strikes de un mismo día son una sola observación del estado del mercado (sección 7.2).




Figura 50. Dimensiones de confianza y sus indicadores. Cada dimensión se reporta con un estado explícito y su etiqueta; el color nunca comunica el estado por sí solo.

5.3 Calibración y reglas de puntuación

La calibración de probabilidades se ajusta en un tramo temporal separado del de entrenamiento y del de prueba. Las reglas de puntuación son propias (Gneiting y Raftery, 2007):

$$\text{Brier} = \frac{1}{N} \sum_i (p_i - o_i)^2 \quad \text{para eventos binarios,} \quad (17)$$

$$\text{CRPS}(F, y) = \int_{-\infty}^{\infty} (F(z) - \mathbb{1}\{y \leq z\})^2 dz = 2 \int_0^1 \rho_{\tau}(y - F^{-1}(\tau)) d\tau, \quad (18)$$

y la pérdida cuantílica ρ_{τ} para percentiles individuales. La segunda igualdad de (18) conecta directamente los pronósticos cuantílicos con el CRPS (Gneiting y Ranjan, 2011). Las puntuaciones se acompañan de curvas de calibración, cobertura y ancho de intervalos (figuras 51 y 52).




Figura 51. Diagrama de fiabilidad de un pronóstico de evento en el mundo sintético. El modelo sobreconfiado empuja las probabilidades hacia los extremos: su curva es más plana que la diagonal y su Brier, peor.




Figura 52. Histogramas PIT de pronósticos de distribución. Un pronóstico calibrado da valores $F(y)$ uniformes; intervalos demasiado estrechos producen forma de U y demasiado anchos, una joroba.

5.4 Conformal adaptativo

Como envoltura de intervalos se prueba la inferencia conformal adaptativa (Gibbs y Candès, 2021). Si $\text{err}_t = \mathbb{1}\{y_t \notin \hat{C}_t(\alpha_t)\}$, el nivel efectivo se actualiza como

$$\alpha_{t+1} = \alpha_t + \gamma(\alpha - \text{err}_t), \quad \left| \frac{1}{T} \sum_{t=1}^T \text{err}_t - \alpha \right| \leq \frac{\max\{\alpha_1, 1 - \alpha_1\} + \gamma}{\gamma T}. \quad (19)$$

La cota garantiza que la tasa de error *promedio a largo plazo* converge a α sin supuestos sobre la distribución. Con horizonte h , el error de la etiqueta que vence en t solo se conoce en t : la actualización usa exclusivamente errores madurados (figura 42).




Figura 53. Intervalos del 90 % ante un cambio de volatilidad en la sesión 500 y otro en la 750 (datos sintéticos). El método de nivel fijo tarda en ajustar su ventana; el adaptativo reacciona antes.




Figura 54. Cobertura móvil de 50 sesiones. Ambos métodos terminan cerca del 90 % en el promedio de largo plazo, pero el de nivel fijo pasa muchas sesiones por debajo del 75 %: la garantía agregada oculta fallas locales.




Figura 55. Trayectoria del nivel efectivo α_t : baja cuando los errores se acumulan y sube cuando sobra cobertura.

⚠ Qué no concluir

El control de cobertura a largo plazo no implica que mañana, o en cada régimen, exista exactamente la cobertura nominal; tampoco convierte el intervalo en una probabilidad de rentabilidad.

5.5 Abstención

Una entrada nueva requiere tres cosas a la vez: datos aptos, estabilidad suficiente del ajuste y evidencia predictiva relevante (figura 56). Si falta cualquiera, se bloquean los incrementos basados en señal y se comunica el problema. Las reducciones exigidas por límites de riesgo definidos de antemano se evalúan aparte, con datos adecuados.




Figura 56. Regla de abstención. La rama de la izquierda no depende del modelo: abstenerse de la señal no significa ignorar una exposición existente.

✓ Criterio para avanzar

Calibración aceptable en el tramo reservado, cobertura estable por subperiodos y regla de abstención ejercitada en sesiones con datos degradados sin producir decisiones basadas en señal.

6 Decisión de posición y riesgo conjunto

ENTRADAS	PROCESO	SALIDAS	CONTROLES
Pronósticos $\mathbb{P}$ calibrados por activo y horizonte, posición actual, costos, límites y estado de confianza.	Construir escenarios conjuntos, optimizar rendimiento, CVaR y costos, y aplicar una zona de no operación.	Región de pesos estables o acción discreta (mantener, aumentar, reducir), con su razón y su riesgo conjunto.	Unidades y horizontes compatibles; ninguna recomendación sin pasar por límites y abstención.

6.1 Escenarios conjuntos físicos

El riesgo de una cartera depende de cómo se mueven juntos sus activos; la suma de riesgos individuales no lo reproduce. Los escenarios conjuntos se construyen con un modelo de factores de mercado y sector, $R_i = \alpha_i + \beta_i^\top f + \varepsilon_i$, y una covarianza regularizada por contracción hacia una matriz estructurada (Ledoit y Wolf, 2004). Como competidor se usa dependencia t (Demarta y McNeil, 2005), que produce más movimientos extremos conjuntos con la misma correlación lineal (figuras 57 y 58), y escenarios de estrés en los que la dependencia es distinta de la de calma (figura 59).




Figura 57. Cópula gaussiana con correlación 0.5 (datos sintéticos). En rojo, los escenarios en que ambos activos quedan por debajo de su cuantil 2.5 %.




Figura 58. Cópula t con tres grados de libertad y la misma correlación: la frecuencia de caídas conjuntas extremas casi se duplica.




Figura 59. Dos regímenes con dependencia distinta. Un modelo que impone la misma dependencia en calma y en crisis subestima el riesgo conjunto justo cuando importa.

6.2 El problema costo–riesgo–rendimiento

Para acciones y ETF, con pesos w , retorno aleatorio conjunto R al horizonte de decisión y posición actual w_{actual} , el problema inicial es

$$\min_{w \in \mathcal{C}_t} -\mathbb{E}_{\hat{p}_t}[w^\top R] + \lambda \text{CVaR}_{\alpha, \hat{p}_t}(-w^\top R) + c(w - w_{\text{actual}}). \quad (20)$$

Con S escenarios r_s y la representación de [Rockafellar y Uryasev \(2000\)](#), $\text{CVaR}_\alpha(L) = \min_\zeta \zeta + \frac{1}{(1-\alpha)S} \sum_s (L_s - \zeta)^+$, y con costos proporcionales $c(\Delta w) = \kappa^\top |\Delta w|$, el problema es un programa

lineal:

$$\begin{aligned}
 \min_{w, b, v, \zeta, z} \quad & -\hat{\mu}^\top w + \lambda \left(\zeta + \frac{1}{(1-\alpha)S} \sum_{s=1}^S z_s \right) + \kappa^\top (b + v) \\
 \text{s.a.} \quad & z_s \geq -r_s^\top w - \zeta, \quad z_s \geq 0, \quad s = 1, \dots, S, \\
 & w = w_{\text{actual}} + b - v, \quad b, v \geq 0, \\
 & \mathbf{1}^\top w + \kappa^\top (b + v) \leq 1, \quad 0 \leq w \leq w_{\text{máx}}, \quad w \in \mathcal{C}_t.
 \end{aligned} \tag{21}$$

$\text{CVaR}_{0.95}$ es el promedio del 5 % peor de las pérdidas simuladas (figura 60). El conjunto factible $\mathcal{C}_t$ recoge las restricciones de la tabla 6. Rendimiento, riesgo y costos deben expresarse en las mismas unidades y el mismo horizonte; los costos incluyen compra y venta, fracciones de acción, mínimos por operación y, cuando corresponda, conversión de moneda.

Tabla 6. Restricciones del conjunto factible $\mathcal{C}_t$.

Restricción	Forma lineal típica
Presupuesto y caja	$\mathbf{1}^\top w + \text{costos} \leq 1$; sin apalancamiento en la primera versión
Concentración	$w_i \leq w_{\text{máx}}$ por activo
Exposición sectorial	$\sum_{i \in \text{sector}} w_i \leq s_{\text{máx}}$
Beta de la cartera	$\beta^\top w \leq \beta_{\text{máx}}$
Rotación	$\mathbf{1}^\top (b + v) \leq \text{rot}_{\text{máx}}$ por sesión
Liquidez	valor negociado $\leq$ fracción del volumen diario promedio
Presupuesto de riesgo (opcional)	$\text{CVaR}_\alpha(-w^\top R) \leq b_{\text{riesgo}}$

N Homogeneidad del objetivo

Sin restricciones activas, el objetivo (20) con costos nulos es positivamente homogéneo: duplicar w duplica el rendimiento esperado y el CVaR. La solución tiende entonces a los extremos —toda la caja o la frontera de $\mathcal{C}_t$ — y es muy sensible a λ . En un experimento sintético de la implementación de referencia (prueba `test_objetivo_homogeneo_lleva_a_extremos`), con escenarios a cinco sesiones, $\lambda = 0.01$ lleva a los límites de concentración y $\lambda = 0.02$ a caja total. Conviene fijar la escala con un presupuesto de riesgo explícito (última fila de la tabla 6), que además es más fácil de interpretar.

6.3 CVaR: qué mide y qué no




Figura 60. Distribución simulada de pérdidas a cinco sesiones de una cartera sintética de cuatro activos. El VaR 95 % es el umbral del 5 % peor; el CVaR 95 % es el promedio de esa cola.




Figura 61. Suma ponderada de los CVaR individuales frente al CVaR de la cartera. La diferencia, que es el beneficio de diversificación, casi desaparece en el escenario de estrés.

⚠ Qué no concluir

El CVaR evalúa el promedio de pérdidas en la cola especificada *bajo los escenarios supuestos*. No es un límite garantizado de pérdida: si los escenarios subestiman la dependencia o las colas, el CVaR subestima el riesgo.

6.4 Zona de no operación y estabilidad de la decisión

Un cambio pequeño de peso debe justificar sus costos y superar una banda de incertidumbre. El rendimiento esperado es la entrada más ruidosa del problema; al remuestrear escenarios y perturbar $\hat{\mu}$, el óptimo recorre buena parte de la frontera del presupuesto de riesgo (figura 62). Por eso la salida no es un punto sino una *región casi óptima*

$$\mathcal{R}_\delta = \{w \in \mathcal{C}_t : \hat{\mu}^\top w \geq \hat{\mu}^\top w^* - \delta\}, \quad (22)$$

con δ del orden de la dispersión bootstrap del valor del óptimo. La regla es simple: si $w_{\text{actual}} \in \mathcal{R}_\delta$, mantener; si no, moverse solo hasta la región, con el traslado de menor costo $\arg \min_{w \in \mathcal{R}_\delta} \kappa^\top |w - w_{\text{actual}}|$, no hasta el punto w^* . La recomendación se expresa como región o como acción discreta (mantener, aumentar, reducir, cerrar), evitando falsa precisión como “7.431 %” cuando el rango razonable es amplio (figura 63).




Figura 62. Región casi óptima en el plano de pesos de dos activos (supuesto: el rendimiento esperado tiene una desviación estándar del 30 % de su valor). Los puntos son óptimos remuestreados; la línea discontinua, el borde interior de la región. La cartera actual dentro de la región se mantiene; la que excede el presupuesto se reduce solo hasta la región.




Figura 63. Distribución del peso óptimo en A entre remuestreos. La cifra puntual aparenta una precisión que el rango del 10 % al 90 % desmiente.

6.5 Fase posterior: optimización robusta

En una fase posterior la distribución puntual $\hat{P}_t$ se reemplaza por un conjunto de distribuciones plausibles y se optimiza el peor caso dentro de él:

$$\min_{w \in \mathcal{C}_t} \sup_{Q \in \mathcal{B}_\varepsilon(\hat{P}_t)} \mathbb{E}_Q[\ell(w, R)], \quad \mathcal{B}_\varepsilon(\hat{P}_t) = \{Q : W(Q, \hat{P}_t) \leq \varepsilon\}. \quad (23)$$

Una bola de Wasserstein es una opción natural (figura 64); para pérdidas lineales por tramos, como la del CVaR, el problema admite reformulaciones tratables (Mohajerin Esfahani y Kuhn, 2018). El radio se selecciona con validación temporal y pruebas de sensibilidad, no a partir de un porcentaje de confianza inventado.




Figura 64. Conjunto de ambigüedad de Wasserstein. La decisión se protege contra el peor caso dentro de la bola, que puede no contener a la distribución verdadera.

⚠ Qué no concluir

Las garantías teóricas de esta familia dependen de supuestos (por ejemplo, muestras independientes y colas controladas) que no se trasladan automáticamente a mercados dependientes y cambiantes.

6.6 Control predictivo con horizonte móvil

Después se prueba el control predictivo: planear varias decisiones, ejecutar solo la primera y recalcular con datos nuevos (Boyd et al., 2017) (figura 65):

$$\max_{w_t, \dots, w_{t+H-1}} \sum_{k=0}^{H-1} \left(\hat{\mu}_{t+k}^\top w_{t+k} - \lambda \mathcal{R}_{t+k}(w_{t+k}) - c(w_{t+k} - w_{t+k-1}) \right). \quad (24)$$

Requiere escenarios temporales coherentes entre horizontes, no simplemente marginales de 1, 5 y 20 días ensambladas.




Figura 65. Horizonte móvil. En cada sesión se optimiza una trayectoria de pesos y solo se ejecuta su primer paso.

6.7 Si se gestionan opciones

Si la posición incluye opciones, el P&L lineal se sustituye por la *revaluación completa* bajo escenarios conjuntos de subyacente, superficie, paso del tiempo y ejercicio o asignación. La aproximación delta–gamma–vega sirve como diagnóstico, no como valoración fiable de toda opción en movimientos grandes (figuras 66 y 67).




Figura 66. P&L a un día de un call a 30 días en el dinero: revaluación completa frente a aproximaciones por griegas. Para movimientos grandes, delta-gamma sobrestima la ganancia y, a la baja, inventa una pérdida que el call no puede tener.




Figura 67. El mismo call cuando la volatilidad sube al caer el precio. Añadir vega no arregla la aproximación en los extremos.

⓪ Pendiente de definir

Confirmar si la posición del usuario incluye o incluirá opciones antes de construir esta rama.

✔ Criterio para avanzar

Riesgo factible bajo todas las restricciones y resultados estables en pruebas de estrés: la recomendación no cambia de signo ante perturbaciones plausibles de escenarios, costos y $\hat{\mu}$.

7 Protocolo de evidencia

ENTRADAS	PROCESO	SALIDAS	CONTROLES
Registro previo de objetivos, transformaciones y variantes; series de pronósticos y decisiones fuera de muestra.	Particiones temporales con purga, comparación incremental, pruebas de pronóstico y de política, corrección por selección y estrés.	Estimaciones de mejora con intervalos por bloques, veredicto por objetivo y horizonte, informe de estrés.	Umbrales fijados antes del holdout; “evidencia insuficiente” cuando el intervalo no se separa de cero.

7.1 Registro previo

Antes de probar nada se registran los objetivos, las transformaciones de variables y el número de variantes que se evaluarán. Cada experimento posterior queda en el registro, haya funcionado o no: el número total de pruebas es un insumo de la corrección por selección (sección 7.5).

7.2 Particiones temporales, purga y tamaño efectivo

Se separan cuatro tramos con funciones distintas: entrenamiento, ajuste de hiperparámetros, calibración y prueba final. La validación es *walk-forward*, sin particiones aleatorias, y con purga de las observaciones cuya etiqueta cruza una frontera entre tramos (López de Prado, 2018). Cuando el esquema pueda reintroducir observaciones correlacionadas se añade un embargo (figura 68).




Figura 68. Validación *walk-forward*. Cada ventana entrena con el pasado, ajusta, calibra y prueba en tramos sucesivos separados por purga y embargo; la prueba final queda reservada hasta el final.

La dependencia reduce la información disponible más de lo que sugiere el número de filas. Con etiquetas solapadas de h sesiones, la autocorrelación inducida es $1 - k/h$ y el tamaño efectivo es aproximadamente n/h (figura 69); con N activos de correlación media $\bar{\rho}$, el número de activos independientes equivalentes es $N/[1 + (N - 1)\bar{\rho}]$ (figura 70). Por eso los intervalos se calculan con bloques temporales y teniendo en cuenta la dependencia entre activos.




Figura 69. Observaciones efectivas en 500 sesiones según el horizonte de la etiqueta: un pronóstico a 20 sesiones tiene del orden de 25 observaciones independientes.




Figura 70. Activos independientes equivalentes según la correlación media. Cinco acciones con correlación 0.6 equivalen a menos de dos.

7.3 Comparación incremental

La pregunta de investigación se responde con una escalera de conjuntos de información (figura 71): A, precio, volumen y volatilidad; B, A más la distribución Q actual; C, B más cambios simples; D, C más transporte e innovaciones; E, D más aceleración y regímenes. Se compara dentro de una misma familia de predicción para atribuir el cambio a la información adicional y no al aumento simultáneo de capacidad del modelo.




Figura 71. Comparación incremental A–E. La hipótesis principal corresponde al paso de C a D.

7.4 Dos pruebas independientes: pronóstico y política

Una señal puede predecir mejor y no pagar sus costos. Por eso hay dos pruebas separadas:

- **Mejora de pronóstico:** diferencial de reglas de puntuación (1) por objetivo y horizonte.
- **Mejora de política de posición:** rendimiento neto, drawdown, pérdidas de cola, rotación y exceso frente a un benchmark de riesgo comparable, contra las referencias de la tabla 7.

Tabla 7. Referencias para la prueba de política. Se alinean moneda, aportaciones, horarios y exposición.

Referencia	Qué controla
Mantener las posiciones	El valor de no hacer nada, incluidos costos evitados.
SPY con dividendos	La exposición pasiva al mercado.
Control de volatilidad sencillo	Si la mejora es solo gestión de riesgo genérica.
Pesos iguales	Para selección de acciones: si el modelo supera una asignación ingenua.

7.5 Sesgo de selección

Probar muchas variantes y quedarse con la mejor infla el resultado aunque ninguna tenga ventaja real. Bajo la hipótesis nula, el máximo esperado de N ratios de Sharpe independientes con varianza V es aproximadamente (Bailey y López de Prado, 2014)

$$\widehat{SR}_0 = \sqrt{V} \left[(1 - \gamma) \Phi^{-1} \left(1 - \frac{1}{N} \right) + \gamma \Phi^{-1} \left(1 - \frac{1}{N_e} \right) \right], \quad (25)$$

con γ la constante de Euler–Mascheroni. El Sharpe deflactado es la probabilidad de que el Sharpe verdadero supere ese umbral, corrigiendo por asimetría $\hat{\gamma}_3$ y curtosis $\hat{\gamma}_4$ de T rendimientos:

$$\text{DSR} = \Phi \left(\frac{(\widehat{SR} - \widehat{SR}_0) \sqrt{T-1}}{\sqrt{1 - \hat{\gamma}_3 \widehat{SR} + \frac{\hat{\gamma}_4 - 1}{4} \widehat{SR}^2}} \right). \quad (26)$$

Se usa como diagnóstico adicional, junto con la evaluación fuera de muestra y el bootstrap por bloques; no como certificado definitivo (figuras 72 y 73).




Figura 72. Sharpe anual máximo esperado entre N estrategias sin ninguna ventaja real. Con dos años de datos diarios y cien variantes, el mejor resultado ronda 1.8 por puro azar; los puntos confirman la aproximación por simulación.




Figura 73. Sharpe deflactado de un mismo resultado observado según el número de variantes probadas (supuestos en el eje).

7.6 Intervalos por bloques y evidencia insuficiente

La mejora media del diferencial de pérdida se estima con bootstrap de bloques móviles (Künsch, 1989), que conserva la dependencia dentro de cada bloque. Si el intervalo no permite distinguir la mejora de cero, el veredicto es *evidencia insuficiente*, no “casi significativo” (figuras 74 y 75).




Figura 74. Distribución bootstrap de la mejora media del modelo D sobre el C (serie sintética con autocorrelación). El intervalo del 90 % excluye el cero.




Figura 75. Una mejora media menor con la misma variabilidad: el intervalo contiene el cero y el veredicto es evidencia insuficiente.

7.7 Pruebas de estrés

Tabla 8. Pruebas de estrés. Ningún horario ni umbral se selecciona con el periodo final.

Perturbación	Qué se observa
Choques de mercado y de correlación	CVaR, límites y cambio de recomendación.
Spreads más amplios	Ancho de bandas, estados de confianza y abstención.
Retrasos y cotizaciones incompletas	Que la decisión use solo datos disponibles en el corte.
Interrupciones y degradación del proveedor	Que un fallo no se convierta en orden.
Resultados trimestrales y cambios de dividendo	Conversión americana, forward y deformación por plazo.
Revisiones de datos	Reproducibilidad con los datos conocidos en cada momento.
Órdenes parcialmente ejecutadas	Reconciliación de posiciones y caja.

7.8 Regla de avance

✓ Criterio para avanzar

Un modelo avanza si mejora la métrica definida de antemano, mantiene una calibración aceptable y produce decisiones estables frente a perturbaciones plausibles. Los umbrales numéricos se fijan antes del holdout con el presupuesto de riesgo acordado.

⚠ Qué no concluir

Llegar a diciembre con el sistema operativo no equivale a haber demostrado ventaja estadística. Un sistema que funciona sin fallas y una hipótesis confirmada son dos entregables distintos.

8 Arquitectura y operación diaria

ENTRADAS	PROCESO	SALIDAS	CONTROLES
Snapshots, parámetros versionados, posiciones y caja, calendario de mercado.	Ejecutar la cadena de módulos en horarios fijos, registrar cada resultado y exponerlo por API e interfaz.	Informe diario, recomendación o abstención, órdenes simuladas idempotentes y reconciliadas.	Corrida reproducible con el mismo snapshot; ningún fallo aguas arriba se convierte en orden.

8.1 Componentes

La implementación propuesta separa un motor cuantitativo en Python, almacenamiento de snapshots en Parquet consultable mediante DuckDB, metadatos de corridas y posiciones en SQLite, una API independiente y una interfaz web para distribuciones y decisiones (figura 76). Es una propuesta de arquitectura, sin selección final de versiones ni benchmark de rendimiento.




Figura 76. Módulos del motor y servicios. Los colores siguen las tres capas: medición Q (azul), predicción IP (naranja) y acción (verde).

Tabla 9. Responsabilidad de cada módulo. El paquete de referencia `quantileflow/` del repositorio contiene versiones mínimas de los bloques matemáticos, usadas para las figuras.

Módulo	Responsabilidad	Referencia
Ingestión	Capturar snapshots inmutables con ambos sellos de tiempo	—
Control de calidad	Filtros, estados de confianza y motivos de exclusión	—
Superficies	SSVI restringido, ajuste convexo, desamericanización	superficies, opciones
Distribuciones	Breeden–Litzenberger, controles, cuantiles y soporte	distribuciones
Transporte y factores	W_1 , W_2 , cambios firmados, PCA funcional, filtros	transporte, filtrado
Predicción IP	Modelos por objetivo y horizonte	pronostico
Calibración	Reglas de puntuación, PIT, conformal adaptativo	calibracion
Escenarios y decisión	Escenarios conjuntos, CVaR, costos, región casi óptima	decision
Regímenes y evidencia	BOCPD, Sharpe deflactado, bootstrap, particiones	regimenes, evidencia
Simulación y registro	Paper, reconciliación y trazabilidad	—

8.2 Trazabilidad y reproducibilidad

Cada resultado conserva hashes de entrada, versión del modelo, parámetros, hora de corte y motivo de abstención. Con el mismo snapshot, la corrida se reproduce exactamente. El siguiente registro es un ejemplo ilustrativo de su forma, no una salida real:

```
{
  "corrida": "2026-09-25T09:45:00-04:00/SPY",
  "hora_corte": "2026-09-25T09:45:00-04:00",
  "snapshot": {"sha256": "3f9a...c21e", "fuente": "proveedor-a", "retraso_s": 0},
  "codigo": {"version": "0.1.0", "commit": "a1b2c3d"},
  "modelos": {"superficie": "ssvi-potencia", "p_h5": "qr-l1", "intervalos": "aci-gamma-0.01"},
  "parametros_sha256": "9d04...7b10",
  "confianza": {"datos": "apto", "ajuste": "degradado", "prediccion": "apto", "decision": "apto"},
  "salida": {"accion": "mantener", "region_peso": [0.30, 0.46], "cvar95_5s": 0.031},
  "abstencion": {"incrementos": "bloqueados", "motivo": "ajuste degradado: bandas de cola anchas"}
}
```

8.3 Calendario diario

La captura empieza en la apertura regular; la primera evaluación se hace alrededor de las 09:45 ET si la calidad alcanza el umbral, con una comprobación posterior a las 10:00 y un registro próximo al cierre (figura 77). Las medias sesiones y los cambios de horario ajustan la agenda. Los canales cierre–apertura y apertura–apertura se mantienen separados.




Figura 77. Agenda de una sesión y canales de cambio. Con una fuente retrasada, el instante ejecutable de decisión se mueve.

8.4 Pantalla

La pantalla muestra distribuciones con bandas, el mapa temporal de cuantiles, los cambios de cola y sus innovaciones, los pronósticos $\mathbb{P}$ diferenciados de $\mathbb{Q}$, la posición actual frente a la propuesta con costos y riesgo conjunto, la razón de la decisión y el historial de calibración (figura 78).



Figura 78. Maqueta de la pantalla principal (estructura, sin datos). Los estados de confianza aparecen en la barra superior con icono y etiqueta.

⚠ Qué no concluir

Un componente de lenguaje puede explicar resultados estructurados, pero no inventar cifras ni decidir tamaños por texto libre. Todo número que aparezca en la explicación debe provenir del registro de la corrida.

8.5 Conector de paper y órdenes

El conector de paper es un componente separado: órdenes idempotentes, reconciliación de posiciones y caja, cancelación y estado de ejecuciones (figura 79). Inicialmente el producto solo recomienda y registra; la simulación de ejecución se incorpora después de comprobar el motor.




Figura 79. Ciclo de una orden simulada. La puerta de validación impide que un fallo de superficie o de datos se convierta silenciosamente en una orden; la clave idempotente evita duplicados en los reintentos.

✓ Criterio para avanzar

Operación reproducible en paper durante un periodo acordado, con fallos inyectados (datos faltantes, proveedor caído, ejecuciones parciales) manejados sin órdenes duplicadas ni posiciones descuadradas.

9 Secuencia de construcción

La construcción avanza por etapas con un criterio verificable de salida (tabla 10). Ninguna etapa se considera terminada porque su código exista: se considera terminada cuando supera su criterio.

Tabla 10. Etapas, entregables y criterios para avanzar.

Etapas	Entregable	Criterio para avanzar
Datos y especificación	Muestra auditada, eventos, horarios y contrato de datos	Cadenas reconstruibles en el instante de decisión; cobertura y costo conocidos
Distribuciones	Superficies restringidas, cuantiles, bandas y <i>replay</i>	Coherencia matemática y estabilidad frente a spreads y colas
Dinámica	Transporte, factores filtrados e innovaciones	Separar ruido de cambios persistentes; cálculo sin información futura
Pronóstico	Referencias y modelos IP con calibración temporal	Mejora incremental fuera de muestra o delimitación honesta de su utilidad
Decisión	Escenarios, CVaR, costos y zona de no operación	Riesgo factible y resultados estables en pruebas de estrés
Paper	Informe diario y reconciliación	Operación reproducible y fallos manejados sin órdenes duplicadas

La estimación inicial de ingeniería es de 6 a 10 semanas para un prototipo integrado con un universo pequeño, si los datos adecuados están disponibles (figura 80). No incluye esperar suficientes observaciones prospectivas para evaluar habilidad predictiva, y se revisa después de auditar la muestra de datos.




Figura 80. Secuencia tentativa. El reparto por etapa es ilustrativo y se superpone parcialmente; lo que la propuesta fija es el total de 6 a 10 semanas de ingeniería, que se revisará tras la auditoría de datos.

 Qué no concluir

La investigación puede concluir que el transporte ayuda al riesgo y no al rendimiento, o que no añade valor sobre las referencias. Ambos son resultados válidos del programa, no fracasos del calendario.

10 Qué priorizar y qué posponer

La prioridad inmediata es todo lo que hace creíble una conclusión, sea positiva o negativa: datos correctos, SSVI restringido con una comparación alternativa, cuantiles con bandas, W_1 y W_2 con la dirección de las colas, filtrado causal, innovación condicionada, pronósticos físicos sencillos, calibración, CVaR con costos, pruebas incrementales y trazabilidad (figura 81).

En una segunda etapa entran la detección de régimen, la autorregresión en espacio de Wasserstein, el conjunto de modelos y la optimización robusta. Como investigación avanzada quedan los modelos neuronales de dinámica de opciones sin arbitraje, si el volumen y la diversidad de datos lo permiten; existen trabajos específicos de neural SDE para superficies y riesgo (Cohen et al., 2021), pero no constituyen evidencia de rentabilidad de esta estrategia.

Se posponen el reinforcement learning, los transformers extensos, la generación de trayectorias por difusión y el criterio de Kelly agresivo. Su complejidad y su sensibilidad a simuladores y pronósticos no se justifican antes de demostrar la utilidad de las señales y la calidad de los datos. Ningún modelo se incorpora solo por ser más sofisticado.




Figura 81. Hoja de ruta. Cada columna exige que la anterior haya superado sus criterios.

En resumen

La decisión arquitectónica central es conservar separadas la medición Q , la predicción $\mathbb{P}$ y la acción sobre la posición. La hipótesis más valiosa para investigar primero es si la innovación de las colas, medida con incertidumbre y relativa al mercado, mejora la gestión de una posición existente. Todo el resto del sistema existe para poder responder esa pregunta con honestidad, incluida la posibilidad de que la respuesta sea no.

A Notación

Tabla 11. Símbolos principales. Algunos se reutilizan con significado local (α , ε , r); el contexto de cada sección los desambigua.

Símbolo	Significado
$S_t, F_{t,\tau}, D(t, T)$	Precio del subyacente, forward al plazo τ y factor de descuento
K, T, τ	Strike, vencimiento y plazo constante de la distribución implícita (30 días)
$k = \ln(K/F), w = \sigma^2 T$	Log-moneyness y varianza implícita total
$\theta_T, \rho, \varphi, \eta, \gamma$	Parámetros SSVI: varianza ATM, asimetría, curvatura y función de potencia
b_i, a_i, m_i, s_i	Bid, ask, mid y medio spread de la cotización i
$q^Q(K), g(k)$	Densidad implícita del precio y función de Durrleman
$x_t(u), u$	Cuantil de $\ln(S_{t+\tau}/F_{t,\tau})$ bajo Q_t y nivel de probabilidad
$W_1, W_2, \Delta x_t(u)$	Distancias de Wasserstein y cambio firmado de cuantiles
$\phi_j(u), s_{tj}$	Autofunciones y puntajes de la PCA funcional
f_t, A, Q, R_t	Estado, transición, ruido de estado y ruido de observación del filtro
$\mathcal{I}_t^{base}, \epsilon_t(u)$	Información base e innovación de la distribución implícita
$Y_{t,h}, d_{t,h}$	Objetivo a horizonte h y diferencial de pérdida entre modelos
$\rho_\tau, \text{CRPS}, \text{Brier}$	Pérdida cuantílica y reglas de puntuación
r_t, H	Longitud de corrida y probabilidad de riesgo de BOCPD
α_t, γ	Nivel efectivo y paso del conformal adaptativo
$w, \kappa, \lambda, \mathcal{C}_t$	Pesos, costos proporcionales, aversión al riesgo y conjunto factible
$\text{CVaR}_\alpha, \mathcal{R}_\delta$	Valor en riesgo condicional al nivel α y región casi óptima
$B_\varepsilon(\hat{P}_t)$	Bola de Wasserstein de radio ε alrededor de la distribución estimada

B Glosario

Arbitraje estático. Combinación de opciones de un mismo instante que asegura ganancia sin riesgo. Sus dos formas son de *calendario* (entre vencimientos) y de *mariposa* (entre strikes).

Breeden–Litzenberger. Identidad que obtiene la densidad implícita como segunda derivada del precio de las calls respecto del strike.

BOCPD. Detección bayesiana en línea de puntos de cambio mediante la posterior de la longitud de corrida.

Conformal adaptativo. Método de intervalos que ajusta su nivel efectivo según los errores recientes y garantiza la tasa de error promedio a largo plazo.

CRPS. Regla de puntuación de pronósticos de distribución; integra la pérdida cuantílica en todos los niveles.

CVaR. Promedio de las pérdidas en la cola especificada (por ejemplo, el 5% peor) bajo los escenarios supuestos.

Desamericanización. Conversión de precios de opciones americanas en equivalentes europeos mediante un modelo con ejercicio anticipado y dividendos.

Embargo y purga. Eliminación de observaciones cuya etiqueta cruza una frontera temporal entre tramos, más un margen de seguridad.

Idempotencia. Propiedad de una orden cuyo reintento con la misma clave no crea duplicados.

Innovación. Parte del cambio de la distribución implícita no explicada por la información base.

PIT. Valor $F(y)$ del pronóstico en el resultado observado; uniforme si el pronóstico está calibrado.

Q y P. Distribución implícita en los precios de las opciones y distribución física de los rendimientos.

Región casi óptima. Conjunto de carteras factibles cuyo valor estimado está dentro de la incertidumbre del óptimo; base de la zona de no operación.

Sharpe deflactado. Probabilidad de que el Sharpe verdadero supere el máximo esperado por azar dado el número de variantes probadas.

SSVI. Parametrización de la superficie de varianza implícita con condiciones suficientes sencillas de ausencia de arbitraje estático.

Transporte óptimo. Forma de mover la masa de una distribución a otra con costo mínimo; en una dimensión es el reordenamiento monótono de cuantiles.

C Decisiones pendientes

Tabla 12. Decisiones que parametrizan el sistema y dónde se usan.

Decisión	Dónde se usa
② Universo definitivo	Datos, escenarios conjuntos, límites de concentración
② Moneda de los 50,000	Costos, conversión, benchmark comparable
② Posiciones actuales	Comparación mantener frente a modificar; zona de no operación
② Horizonte de decisión principal	Objetivos, pérdidas, etiquetas y purga
② Presupuesto y proveedor de datos	Historia disponible, latencia y horario de decisión
② Modelo de costos	Programa lineal y zona de no operación
② Presupuesto de riesgo y límites	Conjunto factible $\mathcal{C}_t$ y reducciones obligatorias
② ¿Se gestionarán opciones?	Rama de revaluación completa
② Umbrales de la regla de avance	Deben fijarse antes de abrir la prueba final

D Reproducibilidad de las figuras

Todas las gráficas se generan con datos sintéticos, semillas fijas y el paquete de referencia `quantileflow/` del repositorio. Se dibujan con `matplotlib` en su estilo por defecto, una figura por gráfica y con textos en inglés; los pies, en español, explican cada una. Desde la raíz del repositorio:

```

pip install -r requirements.txt
python -m pytest                # pruebas de propiedades del núcleo
python docs/propuesta/figuras_src/generar.py # regenera las 62 figuras PNG
make pdf                        # compila este documento

```

Tabla 13. Origen de las figuras.

Figuras	Script	Mundo sintético
s1_*, s2_*	fig_s1_s2.py	Calendario de 30 días; cadena SSVI con spreads y bid nulo
s3_*	fig_s3.py	Panel de 260 sesiones: mercado y acción A, choque común y evento idiosincrático
s4_*, s5_*	fig_s4_s5.py	Supuesto Q/IP; regresión cuantílica; cambio de varianza; desplazamiento de volatilidad
s6_*, s7_*, s9_*	fig_s6_s7.py	Cópulas; cartera de cuatro activos; remuestreo de óptimos; nulas de Sharpe

Las pruebas verifican, entre otras propiedades, que la superficie de referencia cumple las condiciones suficientes de SSVI, que el contraejemplo SVI tiene $g < 0$, que la densidad por Breeden–Litzenberger coincide con la analítica e integra a uno con media igual al forward, que W_2 de una traslación es la traslación, que el CVaR del programa lineal coincide con el empírico, que costos altos producen no operación, que el conformal adaptativo cumple su cota de largo plazo y que el máximo Sharpe esperado coincide con la simulación.

Referencias

- Adams, R. P. y MacKay, D. J. C. (2007). *Bayesian online changepoint detection*. arXiv:0710.3742. <https://arxiv.org/abs/0710.3742>
- Aït-Sahalia, Y. y Lo, A. W. (1998). Nonparametric estimation of state-price densities implicit in financial asset prices. *Journal of Finance*, 53(2), 499–547.
- Alpaca. *Historical option data* (documentación). <https://docs.alpaca.markets/us/docs/historical-option-data>
- Bailey, D. H. y López de Prado, M. (2014). The deflated Sharpe ratio: correcting for selection bias, backtest overfitting and non-normality. *Journal of Portfolio Management*, 40(5), 94–107. <https://www.davidhbailey.com/dhbpapers/deflated-sharpe.pdf>
- Borovička, J., Hansen, L. P. y Scheinkman, J. A. (2016). Misspecified recovery. *Journal of Finance*, 71(6), 2493–2544.
- Boyd, S., Busseti, E., Diamond, S., Kahn, R. N., Koh, K., Nystrup, P. y Speth, J. (2017). Multi-period trading via convex optimization. *Foundations and Trends in Optimization*, 3(1), 1–76. https://stanford.edu/~boyd/papers/cvx_portfolio.html
- Breeden, D. T. y Litzenberger, R. H. (1978). Prices of state-contingent claims implicit in option prices. *Journal of Business*, 51(4), 621–651.
- Burkovska, O. et al. (2018). Calibration to American options: numerical investigation of the de-Americanization method. *Quantitative Finance*. <https://pmc.ncbi.nlm.nih.gov/articles/PMC6034575/>
- Carr, P. y Wu, L. (2009). Variance risk premiums. *Review of Financial Studies*, 22(3), 1311–1341.
- Cboe DataShop. *Option quote intervals* (ficha de producto). <https://datashop.cboe.com/option-quote-intervals>
- Chernozhukov, V., Fernández-Val, I. y Galichon, A. (2010). Quantile and probability curves without crossing. *Econometrica*, 78(3), 1093–1125.
- Cohen, S. N., Reisinger, C. y Wang, S. (2021). *Arbitrage-free neural-SDE market models*. arXiv:2105.11053. <https://arxiv.org/abs/2105.11053>
- Cox, J. C., Ross, S. A. y Rubinstein, M. (1979). Option pricing: a simplified approach. *Journal of Financial Economics*, 7(3), 229–263.
- Demarta, S. y McNeil, A. J. (2005). The t copula and related copulas. *International Statistical Review*, 73(1), 111–129.
- Duan, T., Avati, A., Ding, D. Y., Thai, K. K., Basu, S., Ng, A. y Schuler, A. (2020). NGBoost: natural gradient boosting for probabilistic prediction. *Proceedings of the 37th International Conference on Machine Learning*. arXiv:1910.03225. <https://arxiv.org/abs/1910.03225>
- Gatheral, J. y Jacquier, A. (2014). Arbitrage-free SVI volatility surfaces. *Quantitative Finance*, 14(1), 59–71. arXiv:1204.0646. <https://arxiv.org/abs/1204.0646>
- Gibbs, I. y Candès, E. (2021). Adaptive conformal inference under distribution shift. *Advances in Neural Information Processing Systems*, 34. arXiv:2106.00170. <https://arxiv.org/abs/2106.00170>
- Gneiting, T. y Raftery, A. E. (2007). Strictly proper scoring rules, prediction, and estimation. *Journal of the American Statistical Association*, 102(477), 359–378. <https://sites.stat.washington.edu/people/raftery/Research/PDF/Gneiting2007jasa.pdf>
- Gneiting, T. y Ranjan, R. (2011). Comparing density forecasts using threshold- and quantile-weighted scoring rules. *Journal of Business & Economic Statistics*, 29(3), 411–422.
- Kalman, R. E. (1960). A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1), 35–45.

- Koenker, R. y Bassett, G. (1978). Regression quantiles. *Econometrica*, 46(1), 33–50.
- Künsch, H. R. (1989). The jackknife and the bootstrap for general stationary observations. *Annals of Statistics*, 17(3), 1217–1241.
- Ledoit, O. y Wolf, M. (2004). A well-conditioned estimator for large-dimensional covariance matrices. *Journal of Multivariate Analysis*, 88(2), 365–411.
- Lee, R. W. (2004). The moment formula for implied volatility at extreme strikes. *Mathematical Finance*, 14(3), 469–480.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. Wiley.
- Martin, I. (2017). What is the expected return on the market? *Quarterly Journal of Economics*, 132(1), 367–433.
- Martin, I. y Wagner, C. (2019). What is the expected return on a stock? *Journal of Finance*, 74(4), 1887–1929.
- Mohajerin Esfahani, P. y Kuhn, D. (2018). Data-driven distributionally robust optimization using the Wasserstein metric: performance guarantees and tractable reformulations. *Mathematical Programming*, 171, 115–166. arXiv:1505.05116. <https://arxiv.org/abs/1505.05116>
- Patton, A. J. (2011). Volatility forecast comparison using imperfect volatility proxies. *Journal of Econometrics*, 160(1), 246–256.
- Petersen, A. y Müller, H.-G. (2016). Functional data analysis for density functions by transformation to a Hilbert space. *Annals of Statistics*, 44(1), 183–218.
- Peyré, G. y Cuturi, M. (2019). Computational optimal transport. *Foundations and Trends in Machine Learning*, 11(5–6), 355–607. arXiv:1803.00567. <https://arxiv.org/abs/1803.00567>
- Rockafellar, R. T. y Uryasev, S. (2000). Optimization of conditional value-at-risk. *Journal of Risk*, 2(3), 21–41.
- Ross, S. (2015). The recovery theorem. *Journal of Finance*, 70(2), 615–648.
- Timmermann, A. (2006). Forecast combinations. En *Handbook of Economic Forecasting*, vol. 1, 135–196. Elsevier.
- Zhang, C., Kokoszka, P. y Petersen, A. (2022). Wasserstein autoregressive models for density time series. *Journal of Time Series Analysis*, 43(1), 30–52. arXiv:2006.12640. <https://arxiv.org/abs/2006.12640>